Análisis exploratorio de datos

Base de clientes del reto Orquestador NBA configurable | 100.000 clientes, 45 variables | Archivo: data/oficial/clientes.csv

1. Resumen ejecutivo

- **La base es limpia.** 100.000 clientes sin duplicados y con identificadores únicos. Solo dos columnas tienen vacíos (24,7 % de los clientes) y corresponden a clientes sin contactos en el mes, no a datos perdidos.
- **Los datos son coherentes entre columnas.** Verificamos seis relaciones lógicas (mora, Hogar, OTT, contactos, historial, rangos de los scores) y todas se cumplen.
- **El universo elegible es amplio pero con filtros duros relevantes.** 7,3 % están en mora y 0,53 % tienen 3 o más quejas; 30,1 % tienen calificación C o P, que descarta Terminales.
- **OTT es el producto con mayor probabilidad de compra** (puntaje medio 0,55; 86 % de los clientes superan el umbral de 0,35). Hogar es el más difícil (25 % lo superan) pero es el de mayor valor de negocio.
- **WhatsApp es el canal con mejor respuesta** (puntaje medio 0,41), pero su cupo es limitado. SMS es el de menor respuesta y el de mayor cupo.
- **Los puntajes de canal no son independientes del producto:** el de WhatsApp se mueve con el de OTT (correlación 0,47) y se opone al del asesor (-0,31). Esto implica que repartir los cupos cliente por cliente no es lo mismo que hacerlo en conjunto.
- **Una parte de la base ya tiene el tope semanal agotado:** 1,4 % de los clientes ya recibió 3 contactos esta semana.

Qué contiene este documento: calidad de datos, perfil de los clientes, portafolio actual, contacto y consentimientos, puntajes del modelo y las implicaciones para el motor de decisión.

2. Calidad de los datos

Chequeo	Resultado	Lectura
Filas / columnas	100.000 / 45	Coincide con el diccionario oficial
Filas duplicadas	0	No hay clientes repetidos
id_cliente único	Sí	Un registro por cliente
Columnas con vacíos	2 de 45	canales_contactados_mes y productos_ofertados_mes
Filas con vacíos en esas columnas	24.651 (24,7 %)	Clientes sin contactos en el mes

Coherencia entre columnas

Relación	Resultado
en_mora = 1 exactamente cuando dias_mora > 0	Cumple
tiene_hogar = 0 exactamente cuando arpu_hogar = 0	Cumple
cantidad_ott = Netflix + Amazon Prime + Win	Cumple
contactos_mes = suma de contactos por canal	Cumple
Sin contactos en el mes = historial de canales vacío	Cumple
Puntajes y riesgo de fuga entre 0 y 1	Cumple

Los vacíos de historial no requieren imputación: significan «sin contactos». El motor debe tratarlos como ausencia de historial, no como dato faltante. Las columnas de historial vienen con valores separados por «|».

3. Perfil de los clientes

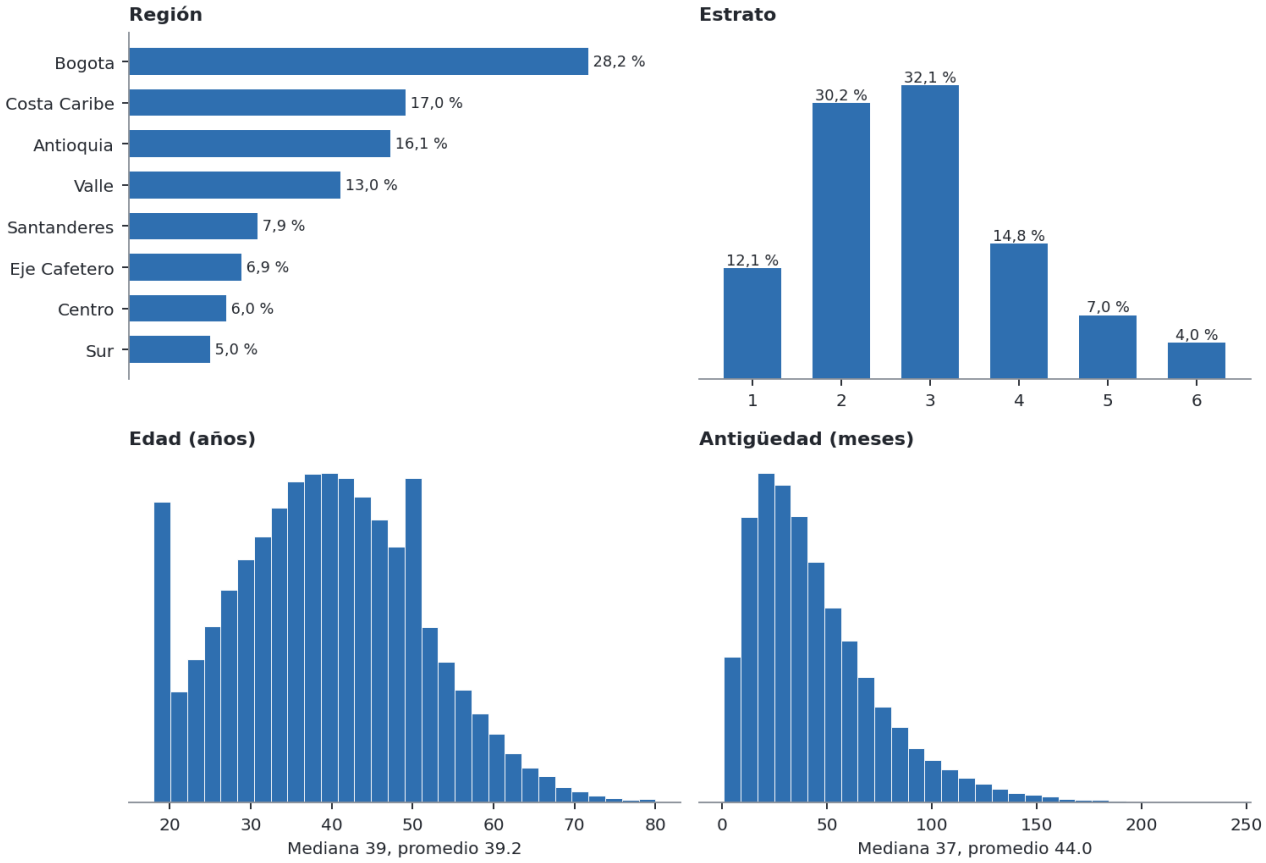


Figura 1. Bogotá concentra 28 % de la base y las tres primeras regiones suman 61 %. Los estratos 2 y 3 son 62 % de los clientes. La antigüedad tiene cola larga: hay clientes de hasta 20 años. El pico en 18 años (4,3 % de la base, el valor más frecuente) sugiere que la edad está acotada por debajo en la fuente.

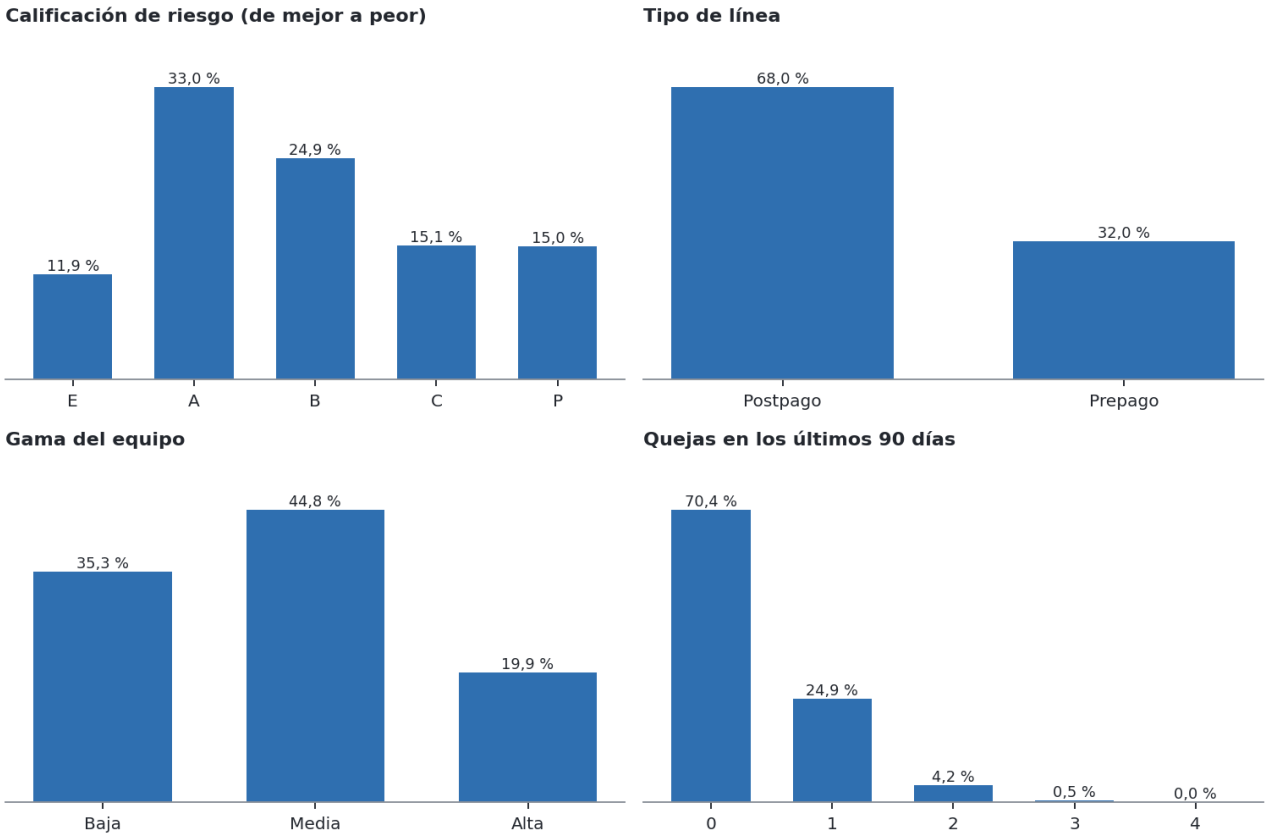


Figura 2. La mayoría de los clientes tiene buena calificación (E, A o B suman 70 %). 70 % no registra quejas. 68 % es postpago.

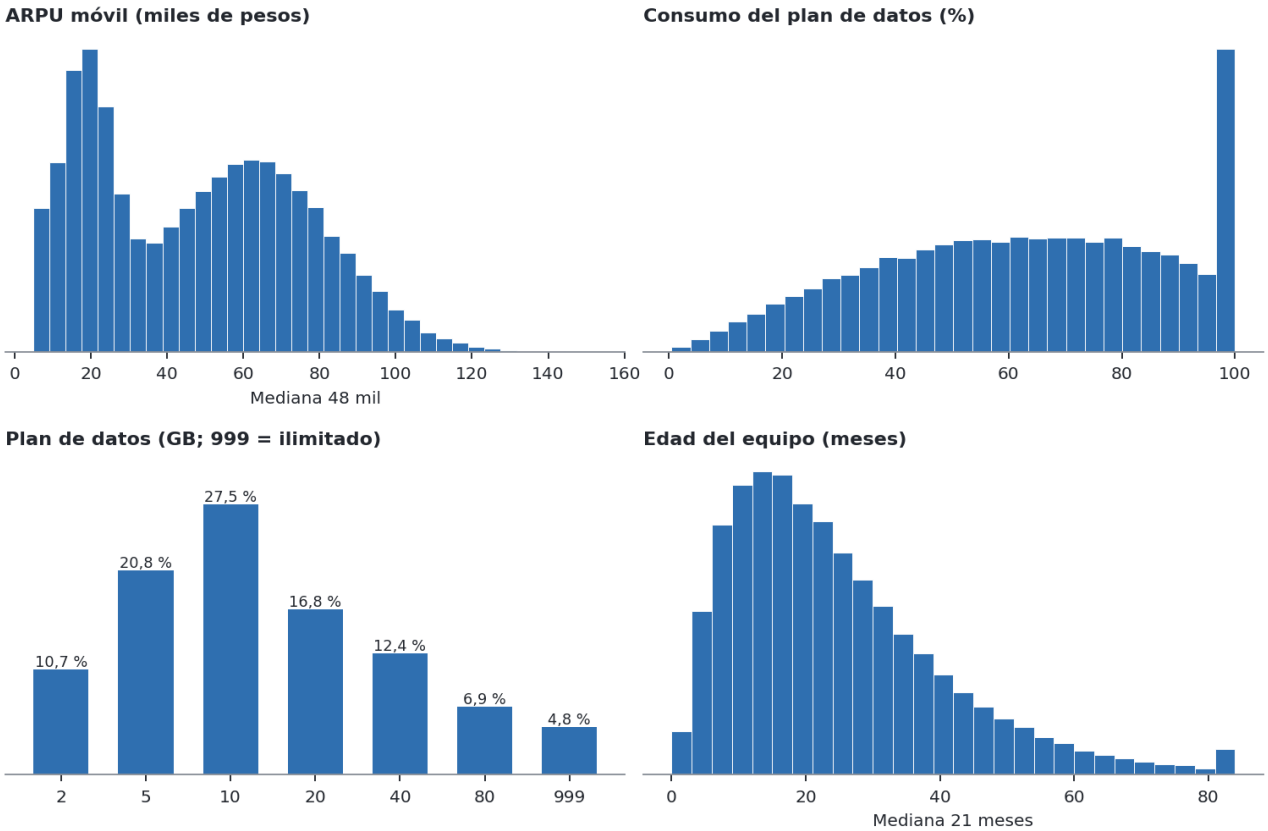


Figura 3. El consumo de datos se acumula en 100 %: 8 % agota su plan, señal de oportunidad de mejora. 59 % tiene un equipo de 18 meses o más, requisito para Terminales.

4. Portafolio actual de productos

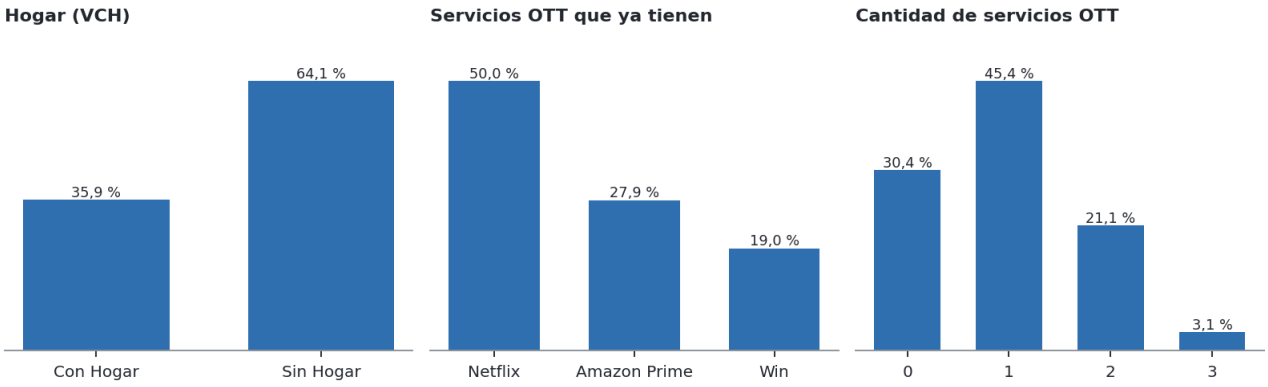


Figura 4. 64 % aún no tiene Hogar: es el público natural de la venta cruzada. El ARPU de Hogar entre quienes lo tienen es de 105 mil pesos en promedio. 30 % no tiene ningún OTT y 3 % ya tiene los tres.

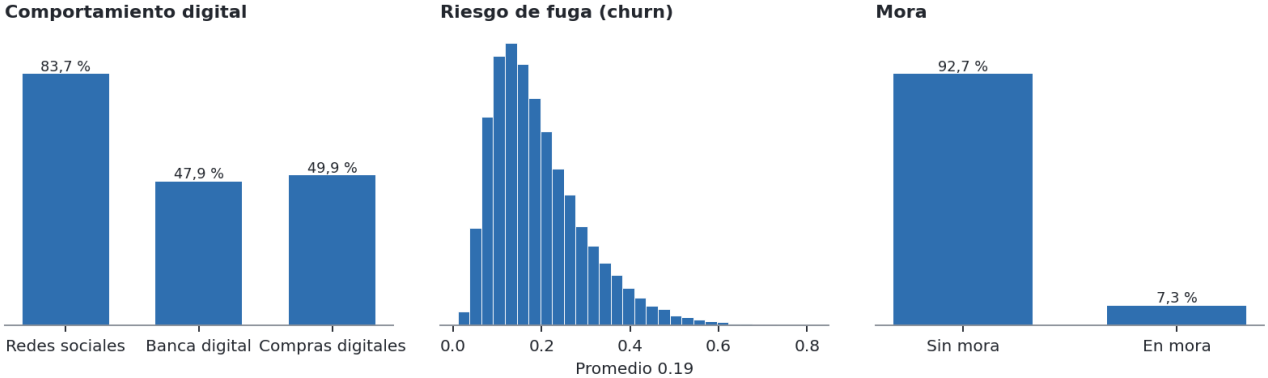


Figura 5. 84 % usa redes sociales y casi la mitad usa banca digital. Entre quienes están en mora, el atraso va de 15 a 90 días (mediana 30).

5. Contacto y consentimientos

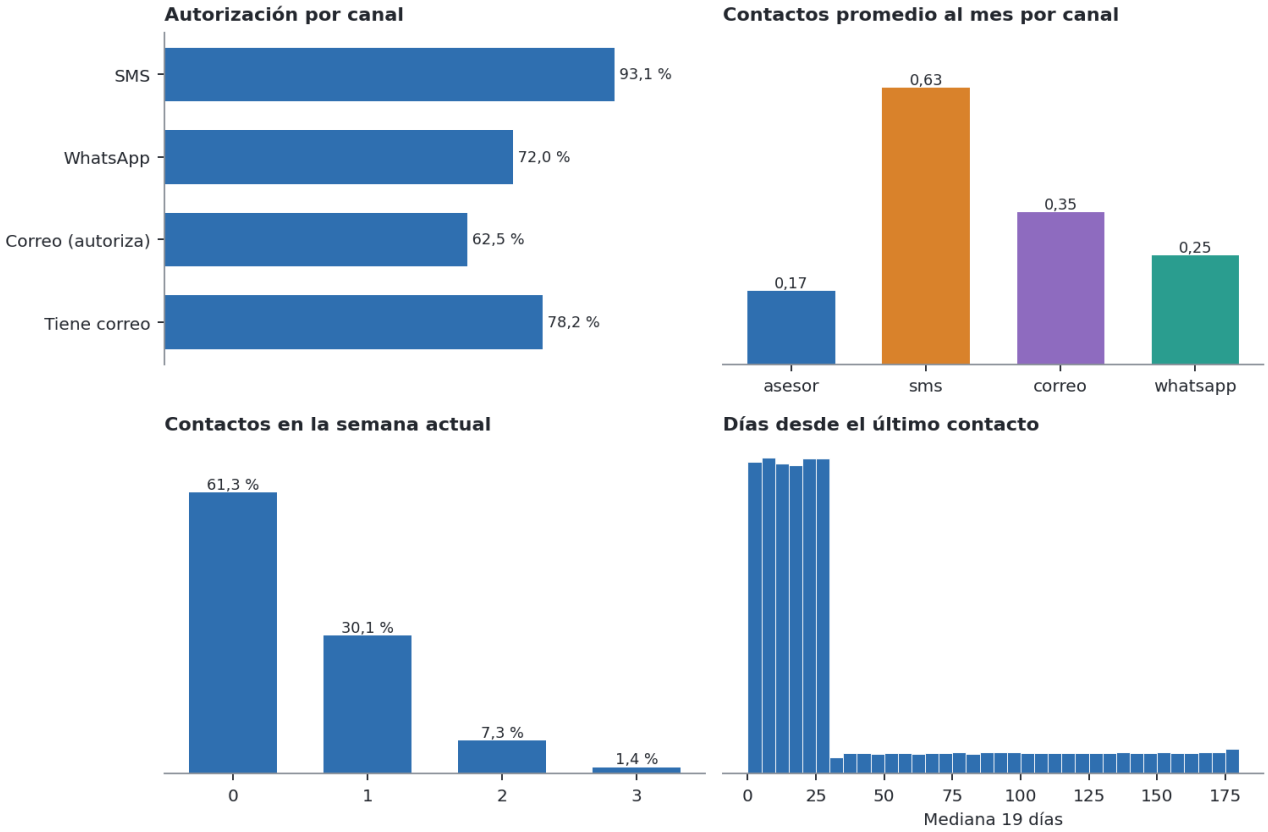


Figura 6. SMS es el canal más autorizado (93 %) y el más usado hasta ahora; correo es el menos autorizado (63 %). 0,75 % no autoriza ningún canal digital. 1,4 % ya alcanzó el tope semanal de 3 contactos.

Historial del mes

Productos ya ofertados en el mes (cada uno no puede repetirse): VCH 37.490 (37,5 %), TER 37.433 (37,4 %), OTT 37.003 (37,0 %). Canales ya contactados: sms 46.934, correo 29.410, whatsapp 22.214, asesor 15.540. Los tres productos se han ofertado con frecuencia casi idéntica, así que ninguno está más «quemado» que otro. Los días desde el último contacto separan dos grupos sin traslape: quienes tuvieron contactos en el mes están entre 0 y 29 días, y quienes no, entre 31 y 180.

6. Puntajes del modelo

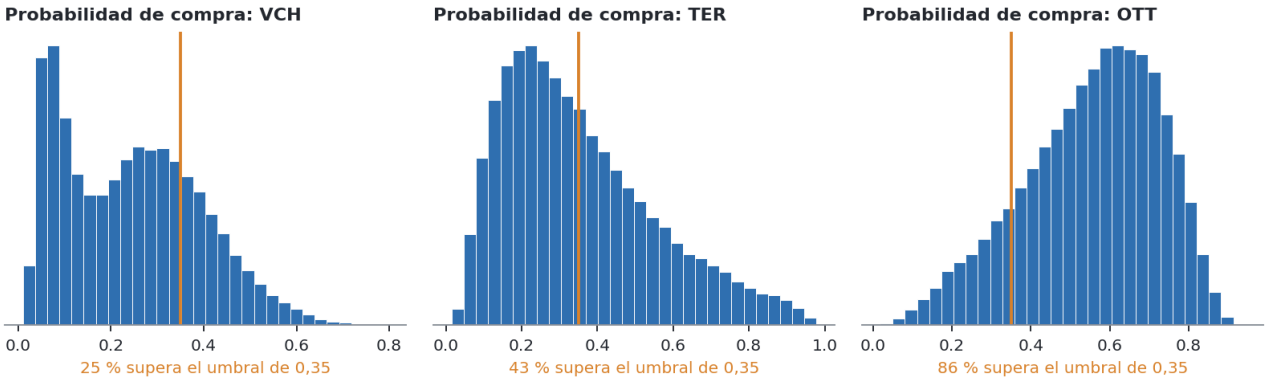


Figura 7. Distribución de la probabilidad de compra por producto. La línea naranja es el umbral mínimo de la configuración inicial.

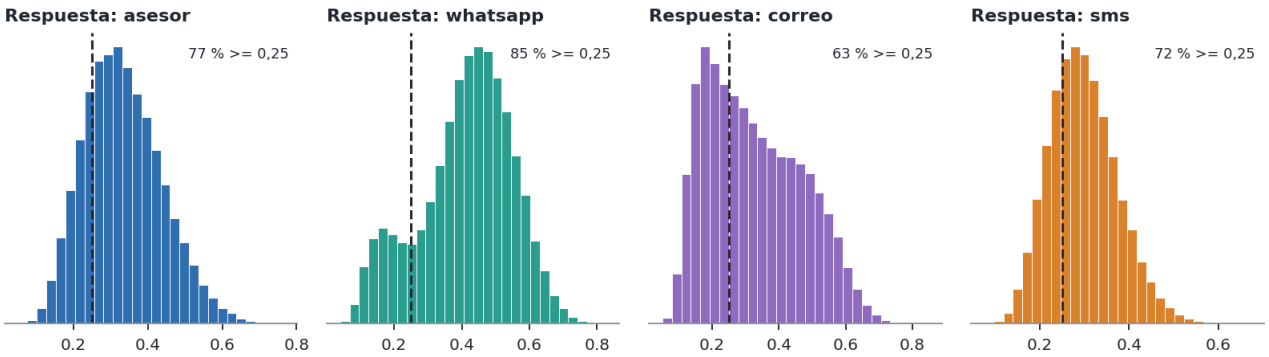


Figura 8. Distribución de la probabilidad de respuesta por canal. La línea punteada es el umbral mínimo de canal.

Producto	Promedio	Mediana	Supera umbral 0,35
VCH	0,243	0,238	25,1 %
TER	0,354	0,313	43,2 %
OTT	0,553	0,574	86,1 %

Canal	Promedio	Mediana	Supera umbral 0,25
asesor	0,333	0,325	77,3 %
whatsapp	0,412	0,428	84,9 %
correo	0,326	0,306	63,2 %
sms	0,298	0,292	71,8 %

Relación entre puntajes

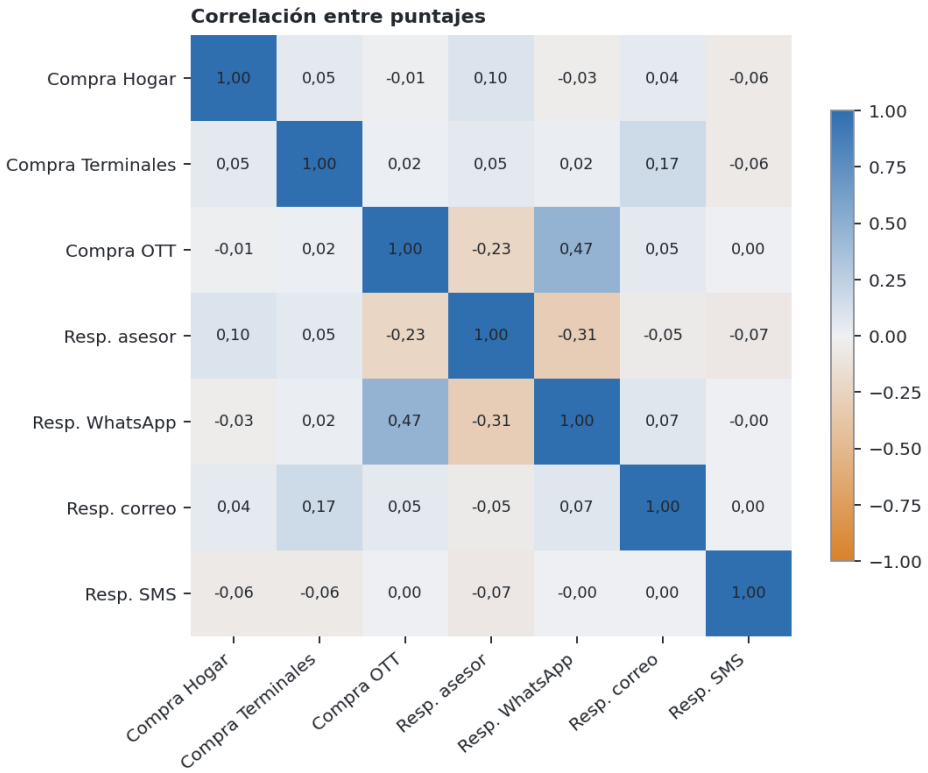


Figura 9. La mayoría de las correlaciones es cercana a cero: los puntajes de producto y de canal aportan información distinta. Las excepciones son WhatsApp con OTT (0,47), asesor con WhatsApp (-0,31) y asesor con OTT (-0,23): quien compra OTT suele responder por WhatsApp y poco al asesor.

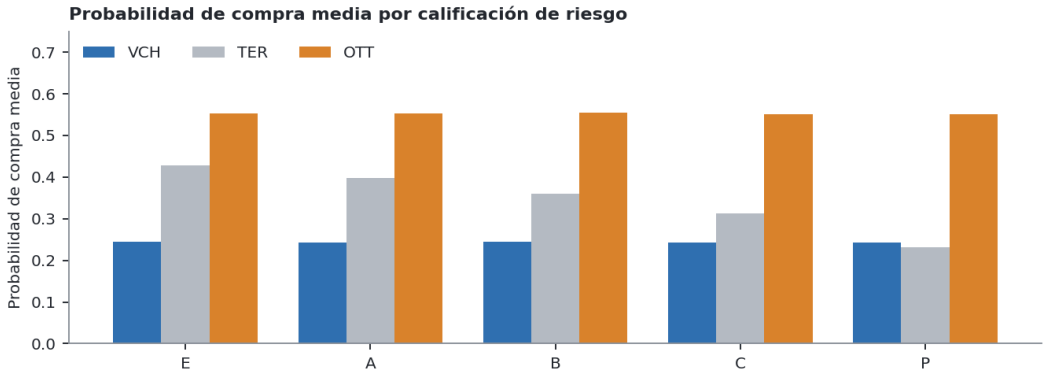


Figura 10. La probabilidad de compra de Terminales cae con el riesgo: 0,43 en la calificación E frente a 0,23 en la P. Esto es coherente con que Terminales solo se ofrezca a las mejores calificaciones.

7. Implicaciones para el motor de decisión

Tamaño del universo elegible por filtros simples (antes de cualquier regla de campaña):

Condición	Clientes	Efecto
En mora	7,3 %	Exclusión total
3 o más quejas en 90 días	0,53 %	Exclusión total
Tope semanal alcanzado (3 contactos)	1,4 %	No se puede contactar esta semana
Calificación C o P	30,1 %	Sin Terminales
No autoriza ningún canal digital	0,75 %	Solo podría atenderse por asesor
Sin filtros duros (sin mora, quejas ni tope)	90,9 %	Universo de partida
Algún producto con compra >= 0,35	93,8 %	Candidatos potenciales

Conclusiones

- **Los canales buenos tienen cupo escaso.** 84.926 clientes superan el umbral de respuesta de WhatsApp y su cupo es 15.000; para el asesor son 77.307 clientes frente a un cupo de 2.500. Esa escasez es la que decide el resultado.
- **Los umbrales cortan mucha base.** Hogar es el producto que más se descarta por probabilidad baja; por eso conviene medir el impacto de cualquier cambio de umbral antes de aplicarlo.
- **La asignación conjunta importa.** Los puntajes de WhatsApp y asesor están relacionados con los de producto, de modo que asignar cliente por cliente agota el cupo bueno con los primeros clientes y deja valor sin capturar.
- **Las variables ya contienen lo necesario para reglas nuevas.** Mora, quejas, calificación, autorizaciones, edad de equipo, banca digital y estrato permiten expresar casi cualquier restricción comercial como una regla de configuración.
- **Cuidado con los valores vacíos de historial:** son clientes sin contactos y deben quedar elegibles para todos los productos y canales por esa condición.

Nota metodológica: todas las cifras se calcularon directamente sobre data/oficial/clientes.csv. Los umbrales y el tope semanal se leen de config_inicial/parametros.yaml. Este análisis describe la base; no evalúa la calidad del modelo que generó los puntajes.